

TECHNICKÁ UNIVERZITA V KOŠICIACH
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

Využitie hybridnej umelej inteligencie v prostredí internetu vecí

Záverečná správa

2020

Dušan Herich
Bc. Martin Groninger
Patrik Schutz
Tomáš Krupa

DEFINÍCIA PROBLÉMU

Primárnym cieľom tohoto zadania je vytvoriť systém, ktorý bude utilizovať prostriedky hybridnej výpočtovej inteligencie na predikciu obsadenosti parkovacích miest v meste Košice. Riešená úloha musí rovnako využívať prostriedky internetu vecí – verejne prístupné IP kamery rozmiestnené na území mesta.

Z tejto definície vyplývajú ďalšie čiastkové úlohy, ktoré je potrebné splniť pre funkčnosť projektu. V prvom rade je potrebné zostaviť model umelej inteligencie, ktorý dokáže počítať pohybujúce sa autá, nakoľko dáta akvirované takýmto modelom sú prerekvizitou pre chod zostávajúcich častí projektu.

Rezultujúc z výpočtovej náročnosti spracovávanie obrazu v reálnom čase pri nasadení relatívne vysokého počtu obrazových zdrojov je odporúčané uplatniť prostriedky „cloud computing“.

Za kľúčovú úlohu sa považuje zostavenie modelu hybridnej výpočtovej inteligencie využívajúceho aspoň dva z prostriedkov (fuzzy systémy, neurónové siete, evolučné algoritmy), spôsobilého vykonávať uvedenú úlohu – predikovať obsadenosť parkovacích miest v meste za čo najkratší časový úsek. To znamená, že je nevyhnutná integrácia s modelom zbierajúcim aktuálne dáta premávky.

RIEŠENIE

Pri riešení zadaného problému bolo nutné vyriešiť niekoľko subsekventných úloh vyžadujúcich použitie rôznych prostriedkov a metódik. Tieto sú rozoberané v nasledujúcich častiach práce.

ZBER DÁT

Na zber dát z premávky v meste boli využité voľne prístupné IP kamery. Väčšina z týchto kamier je rozmiestnená tak, že v ich zábere sa nachádzajú križovatky primárnych a frekventovaných ciest mesta. Z toho vyplýva, že dokážu zachytiť významnú časť mestskej premávky – napríklad vjazdy do mestských častí – čo ich robí suficientnými pre zber dát použitých v ďalších častiach úlohy, nakoľko môžu byť singulárne a infraštruktúrne efektívne v porovnaní s inými prostriedkami internetu vecí. To znamená, že vo významnom počte miest nie je potrebné markantné rozširovanie infraštruktúry, pretože už sú pokryté bezpečnostnými kamerami sledujúcimi aktuálnu premávku.

Za primárnu prednosť daného zdroja dát je možné pokladať už uvedenú jedinečnosť a aktuálnosť dát, ktoré pri dostatočnej koncentrácii kamier môže konkurovať službám zberu informácií z premávky uplatňujúce napríklad mobilné telefóny účastníkov. Nemenej podstatnou je dostupnosť údajov – za predpokladu, že je kamerový systém verejný.


Medzi nevýhody radíme najmä nepresnosť modelov pracujúcich s takýmito obrazovými zdrojmi, ktoré sú frekventovane negatívne ovplyvnené kvalitou obrazu na ktorú má význačný vplyv počasie, časť dňa, prípadne kvalita kamery samotnej a rýchlosť jej internetového pripojenia. Ďalšia markantná slabina je často nízka, alebo nevhodné pokrytie systému.

Využitý systém pozostáva z deviatich verejne prístupných kamier v meste Košice vyznačujúci sa relatívne kvalitným obrazom z hľadiska vyššie uvedených kritérií. Jeho nevýhoda je, so zreteľom na rozľahlosť mesta, nízka hustota, čo malo za následok zníženie počtu, tzn. zväčšenie plochy lokalít, pre ktoré je opodstatnené predikciu vykonávať.


Pre samotný zber dát bol vytvorený systém v programovacom jazyku Python využívajúci balíky CV2 na operácie, akými sú načítanie obrazu a jeho predspracovanie, napríklad prevod na

šedotónový obraz a Tensorflow, ktorý poskytuje model schopný klasifikovať množinu objektov zahrňajúcu autá.

Sytém zberu dát disponoval množinou plôch značiacich výstupy z každej križovatky, vďaka čomu bolo možné jednoducho počítať autá ňou prechádzajúce. Postup počítania je ilustrovaný na obrázkoch Obr.1 a Obr.2. Tu je viditeľné, že započítavané sú len malé osobné vozidlá, ktoré sú smerodatké pre evaluáciu parkovacej situácie.



Obr. 1 Systém označil autá detekované v križovatke



Obr. 2 Modré obdĺžniky reprezentujú miesta, na ktorých systém započítava autá

Vychádzajúc z výpočtovej náročnosti takéhoto spracovania obrazu, bol systém nasadený na platformu cloudového počítania – Amazon Web Services (AWS). Uvedená platforma, ktorá okrem poskytuje „Infraštruktúru ako Servis (IaaS)“, čo znamená, že poskytuje inštancie serverov, na ktorých je možné spúšťať aplikácie. Táto služba je pomenovaná EC2 a disponuje aj serverovými inštanciami, ktoré sú optimalizované na úlohy akými je aj spracovávanie videa.

Aby bolo možné jednoducho pristupovať ku zozbieraným dátam, v aplikácii bežiacej na serveri bolo vytvorené aj REST API. Toto poskytovalo dáta o pohybe áut za ľubovoľný časový úsek od začiatku zberu, nakoľko sa každý záznam o pohybe ukladal aj s časovou pečiatkou, čím bola zaistená čiastočná variabilita pri zostavoaní predikčných modelov.

Na Obr.3 je ilustrovaná časť odpovede zo služby, kde ako je možné vidieť, sa nachádzajú údaje o pohybe pre každý smer na danej križovatke.

```
{
  "snp_toryska":
  {
    "toryska_kvp": 24,
    "toryska_mesto": 36,
    "snp_amfiteater": 64,
    "snp_moldavska": 58
  },
  "palackeho_jantarova":
  {
    "palackeho": 45,
    "jantarova": 28,
    "osloboditelov": 62,
    "protifasistických_bojovníkov": 64
  }
}
```

Obr. 3 Odpoveď z vytvoreného REST API


ZOSTAVENIE MODELU

Po akvirovaní uspokojivej množiny dát bolo možné zostaviť predikčný model. Kvoli povahe dát bol zvolený algoritmus „Fuzzy Adaptive Resonance Theory“ (FuzzyART), čo je model založený na teórii fuzzy množín a neurónových sietí ART1. Využitelnosť nachádza najmä pri rozpoznávaní vzorov, spracovávaní časových radov, problémoch zhukovania a klasifikácie. Vstupné dáta môžu byť tak spojité ako aj diskrétné.

Model nad dátami vykonáva zhukovanie, pričom dovoľuje kontrolovať podobnosť bodov vrámci zhuku. Táto možnosť je založená na architektúre, ktorá zahŕňa dva dôležité pojmy a to:

- Pozornosť – určuje, či nájdené zhuluky sú optimálne,
- Orientácia – pomáha určovať, či sú nájdené zhuluky valídne.

Modely zároveň disponujú schopnosťou adaptovať sa na nové dáta po naučení, čo znamená, že môžu pridať nový zhuk v prípade, že nové dáta nezodpovedajú žiadnemu už nájdenému zhuku.



Obr. 4 Architektúra FuzzyART

Z Obr. 4 vidíme, že model sa skladá z troch vrstiev a výstupnej vrstvy. Celá architektúra využíva jedinou váhu, vďaka čomu je jednoduchšie ju aktualizovať. Ďalšie zostavenie modelu je popísané v kapitole experimenty.

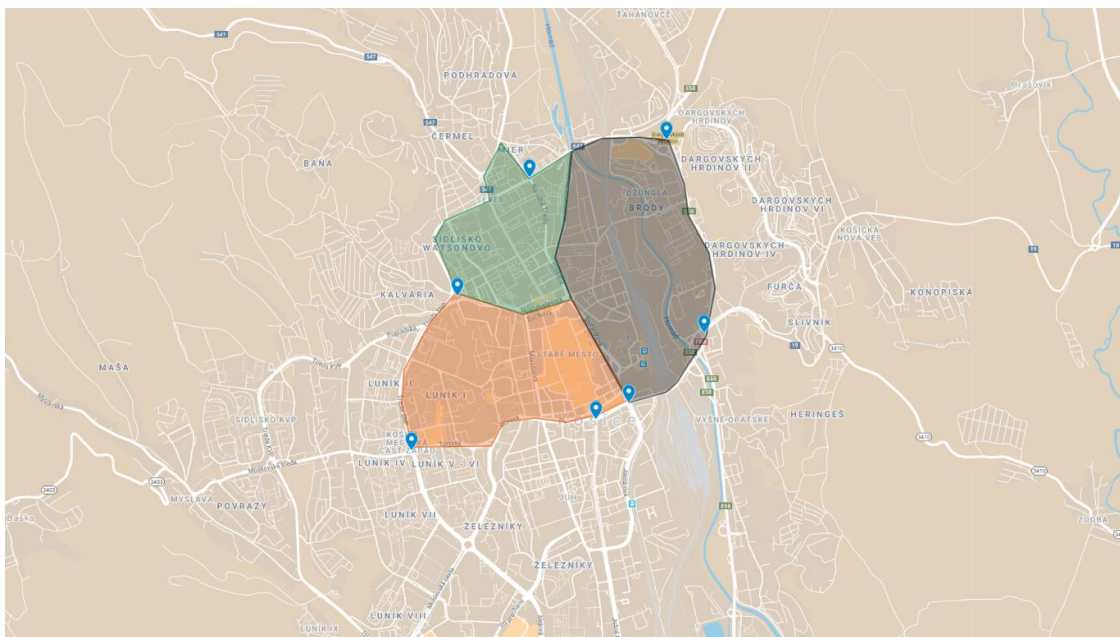
EXPERIMENTY

V podmienkach riešeného zadania bolo testovaných niekoľko modelov využívajúcich rôzne vstupné dáta v zmysle ich spojitosti, pričom ostatné parametre učenia zostali zachované. Natrénované modely boli vyhodnotené na jednej strane empiricky, pričom sa hodnotila predikcia pre daný časový interval v konkrétnej oblasti mesta a na druhej strane boli modely hodnotené aj objektívne pomocou lakt'ovej metódy.

MODEL 1


Kvôli obmedzenému počtu monitorovaných bodov bolo územie mesta rozdelené do troch zón, kde pre každú mali byť predikované hodnoty samostatne. Prvý model využíval dáta ako spojité, vychádzajúc z časových pečiatok zaznamenaných počítačom. Trénovanie prebiehalo v sto epochách.

Pri empirickom evalácii bol uvedený model vyhodnotený ako neúspešný, nakoľko predikcia nezodpovedala skúsenostiam ani čiastočne. Za príčinu takéhoto výsledku považujeme relatívne malú množinu vstupných dát, ktorá bola z praktických dôvodov zbieraná len v obmedzenom časovom intervale (niekoľkých dní).



Obr. 5 Rozdelenie mesta na zóny


Pri objektívnom hodnotení bol neúspech taktiež zrejмый. Prvotný počet nájdených zhlukov po naučení postupne zvyšoval, čo čiastočne podporuje hypotézu o nedostatočnosti dátovej množiny. Výsledok hodnotenia lakt'ovou metódou je ilustrovaný na Obr. 6, kde je viditeľné, že optimálny počet zhlukov je 700, čo by znamenalo aj veľmi náročnú interpretáciu výsledkov.



Obr. 6 Vyhodnotenie modelu 1

MODEL 2

Pri vytváraní daného modelu bol postup rovnaký ako pri predchádzajúcom, ale vstupné dáta boli diskretizované, kedy boli rozdelené do konštantných časových úsekov, za ktorý bol sumarizovaný tok áut. Pri empirickom hodnotení bolo zrejmé, že dosahuje výsledky lepšie ako model predchádzajúci, napriek tomu že stále nedosahoval optimálne výsledky. Tu považujeme za príčinu neuspokojivých výsledkov použitie jedného modelu pre všetky zóny, čo zhoršilo zohľadňovanie špecifik zón samotných, čím sa myslí tok dopravy zo zóny, resp. do zóny v určitej časti dňa. Výsledok laktovej metódy naznačuje optimum 10 zhlukov. Modelom bolo nájdených 13.




Obr. 6 Vyhodnotenie modelu 2

MODEL 3

Posledný zostavený model v skutočnosti pozostáva z troch modelov, čo znamená, že pre každú zónu bol vytvorený jeden. Vstupná dátová množina bola rozdelená podľa príslušnosti ku jednotlivým zónam. Vďaka tomuto sa dátové množiny zmenšili a učenie bolo možné priamočiaro paralelizovať, čím sa proces vytvárania modelu urýchlil.

Empirické vyhodnotenie naznačilo relatívne uspokojivé výsledky predikcie, čo je výsledkom úprav chýb z predchádzajúcich modelov. Lakt'ovú metódu uvádzame iba pre jeden model, nakoľko sú modely medzi sebou veľmi podobné. Lakeť naznačuje optimálny počet štyroch zhlukov, ktoré boli modelmi nájdené, čo znamená jednoduchú interpretáciu výsledkov.



Obr. 7 Vyhodnotenie modelu 3

ZÁVER

Vytvorený systém dokáže zbierať informácie o pohybe áut v meste Košice a úspešne predpovedať parkovaciu situáciu v troch definovaných zónach. Na predikciu využíva techniky hybridnej výpočtovej inteligencie, na počítanie áut spracovanie obrazu pomocou umelej inteligencie, ktoré bolo nasadené na platforme cloudového počítania.

Ďalšie možnosti rozvoja projektu vidíme v prípade lepšieho pokrytia mesta kamerovým systémom, čo by umožnilo predikciu na menších plochách. Okrem toho je možnosť prínosu vo väčšej dátovej množine, čím by sa automaticky zlepšila kvalita predikcie. V neposledom rade bude pri automatizovanom interpretovaní predikcie nutné zvážiť ošetrenie možností autonómneho pridania nových zhlukov.